



1.結果呈現



雖然一開始的正確率不高，但經過幾次的訓練過程後越來越趨近於 **76%**

```
Epoch 20/20  
40000/40000 [=====]  
Test loss: 0.9276220597267151  
Test accuracy: 0.7585
```



可以發現 loss 越低，準確率越高，而最後的 loss 還是些微

的上升，但跟原始 cnn 程式相比好了一些。

```
40000/40000 [=====] - 299s 7ms/step - loss: 1.0969 - acc: 0.6108 - val_loss: 1.1247 - val_acc: 0.6084
Epoch 6/20
40000/40000 [=====] - 294s 7ms/step - loss: 0.9932 - acc: 0.6502 - val_loss: 1.0361 - val_acc: 0.6357
Epoch 7/20
40000/40000 [=====] - 294s 7ms/step - loss: 0.8924 - acc: 0.6879 - val_loss: 0.9441 - val_acc: 0.6749
Epoch 8/20
40000/40000 [=====] - 295s 7ms/step - loss: 0.8111 - acc: 0.7157 - val_loss: 0.8325 - val_acc: 0.7067
Epoch 9/20
40000/40000 [=====] - 298s 7ms/step - loss: 0.7279 - acc: 0.7450 - val_loss: 0.9397 - val_acc: 0.6796
Epoch 10/20
40000/40000 [=====] - 305s 8ms/step - loss: 0.6606 - acc: 0.7705 - val_loss: 0.8148 - val_acc: 0.7214
Epoch 11/20
40000/40000 [=====] - 300s 7ms/step - loss: 0.5936 - acc: 0.7939 - val_loss: 0.8228 - val_acc: 0.7265
Epoch 12/20
40000/40000 [=====] - 303s 8ms/step - loss: 0.5299 - acc: 0.8159 - val_loss: 0.8100 - val_acc: 0.7353
Epoch 13/20
40000/40000 [=====] - 304s 8ms/step - loss: 0.4715 - acc: 0.8359 - val_loss: 0.7987 - val_acc: 0.7402
Epoch 14/20
40000/40000 [=====] - 306s 8ms/step - loss: 0.4134 - acc: 0.8576 - val_loss: 0.7710 - val_acc: 0.7507
Epoch 15/20
40000/40000 [=====] - 306s 8ms/step - loss: 0.3579 - acc: 0.8767 - val_loss: 0.7781 - val_acc: 0.7549
Epoch 16/20
40000/40000 [=====] - 301s 8ms/step - loss: 0.3083 - acc: 0.8927 - val_loss: 0.7844 - val_acc: 0.7587
Epoch 17/20
```

(訓練過程擷取)

2. 討論

環境: Google colab

前置設定: 在一開始執行以下程式

```
!pip install tensorflow==1.14.0
import tensorflow as tf
print(tf.__version__)
```

因為要使用的一些 function 貌似 Tensorflow 2.20 不支援，所

以要降版至 1.14.0

整體模型流程(但看完其他網路文章發現有些層放錯位置):

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_1 (Conv2D)	(None, 32, 32, 64)	1792
conv2d_2 (Conv2D)	(None, 32, 32, 64)	36928
max_pooling2d_1 (MaxPooling2D)	(None, 16, 16, 64)	0
conv2d_3 (Conv2D)	(None, 16, 16, 128)	73856
conv2d_4 (Conv2D)	(None, 16, 16, 128)	147584
max_pooling2d_2 (MaxPooling2D)	(None, 8, 8, 128)	0
conv2d_5 (Conv2D)	(None, 8, 8, 128)	147584
conv2d_6 (Conv2D)	(None, 8, 8, 128)	147584
batch_normalization_1 (Batch Normalization)	(None, 8, 8, 128)	512
max_pooling2d_3 (MaxPooling2D)	(None, 4, 4, 128)	0
flatten_1 (Flatten)	(None, 2048)	0
dense_1 (Dense)	(None, 120)	245880
dense_2 (Dense)	(None, 84)	10164
dropout_1 (Dropout)	(None, 84)	0
dense_3 (Dense)	(None, 10)	850

第一組卷積
+池化層

第二組卷積
+池化層

第三組卷積
+池化層以
及 BN 加快
收斂速度

神經網路
層，其中有
兩層隱藏層

輸出層

這次的話其實設計的過程沒有太大的想法(主要做很多次的 convolution 和看看其他的優化器和 function)，主要是去熟悉這些 function 的參數和意義。

```
model.add(Conv2D(filters=64, kernel_size=3, input_shape=(32, 32, 3), activation='relu', padding='same'))
```

此行意思為有 64 個 filters (即我們稱的 filter 或 kernel)，

kernel 大小為 3×3 ，卷積後輸入以及輸出的圖形大小不變（padding = 'same'，即圖像周圍會補值），輸入的圖形維度為 $32 \times 32 \times 3$ ，使用 relu 啟動函數。由於定義了 64 個 filters，因此本層會輸出 64 個 16×16 的影像。

```
model.add(MaxPooling2D((2, 2), strides=(2, 2)))
```

接下來是池化層，本層參數比較少，我們只要定義 pool size 為 (2,2)，即尺寸縮小為一半。本層接收了上一層卷積層的 64 個 32×32 影像後，會輸出 16 個 14×14 的影像。

```
model.add(BatchNormalization(axis=-1))
```

使得深層神經網絡訓練更加穩定，加快了收斂的速度，甚至同時起到了正則化的作用。可以 training 加速，可以防止 gradient vanishing 的問題，可以幫助 sigmoid 或是 tanh 這種的 activation function 可以讓參數的 initialization 的影響較小

```
model.add(Flatten())
```

接著我們需要一個平坦層，將特徵值轉為一維資料以供後續的全連結層使用。本層接收第三個池化層傳來的 $4 \times 4 \times 128$ (=2048) 資料之後，轉為 1 維有 2048 的值的矩陣。

```
model.add(Dense(120, activation='relu'))
```

建立全連結層中的隱藏層(即傳統神經網路中的全連結層)，指定其神經元數目為 120 個(此數目可調整)，啟用函數使用 Relu。

```
model.add(Dropout(rate=0.25))
```

在各兩層的卷積與池化後，我們加入 Dropout 層，它最大的功用是減少過度擬合。在深度學習的訓練過程中，Dropout 會讓每次 batch run 都依據機率丟棄一定比例的神經元不予計算，使得每一次都好像在訓練不同的神經網路一樣。上方的程式中，我們定義該 Dropout 層每次訓練時要丟棄 25% 的神經元。

```
model.add(Dense(10, activation='softmax'))
```

本模型的最後一層是輸出層，也就是要輸出十種 0~9 的分類值，一般我們都會使用 softmax 作為分類模型輸出層的啟動函數。

```
model.compile(loss='categorical_crossentropy',  
              optimizer=ada(lr=0.01),  
              metrics=['accuracy'])
```

模型建立好之後，接下來要準備訓練此模型，在訓練之前，要使用 `compile` 來定義訓練的參數。損失函數使用深度學習分類模型中最常用的交叉熵 `cross entropy`，梯度下降法使用 `Adagrad`(`learning rate = 0.01`，但看到網路上很多人建議用 `adam`，但還沒特別研究這些 `optimizer` 差別)，模型的評估方式則是以 `accuracy` 為優先。

瑕疵與改進地方:

查看其他網路文章發現 `Dropout` 和 `Batch normalization` 層放錯地方，`Dropout` 層一般加在全連結層後以防止過度擬合，提升模型泛化能力。而很少見到卷積層後接 `Dropout`(原因主要是卷積參數少，不易過擬合)，而且 `Batch normalization` 可替換 `Dropout`，而且表現得更好。但兩者放置位置不同:只有在有全連接的時候用 `Dropout`，在卷積之間使用 `Batch normalization`。

所以程式碼應該為:

```
model.add(Conv2D(filters=128, kernel_size=3, activation='relu', padding='same'))
model.add(BatchNormalization(axis=-1))
model.add(Activation('relu'))
```

或

```
model.add(Dense(120, activation='relu'))  
model.add(Dropout(rate=0.25))
```